# ЛР3. Улучшение поиска в RAG

SciFact и разбиение из ЛР2. Dev: 90 утверждений, из них 60 с обоснованием. Holdout: 210 и 128 соответственно. Бюджет 2048 входных токенов, top-3, модель и промпты ЛР2.

## Прогноз

BM25 должен помочь с редкими обозначениями, Dense — с перефразированием. RRF может сохранить находки обоих методов. Переранжирование может улучшить порядок выдачи, но ответ зависит и от сборки контекста, и от модели.

## Поиск на dev

| Вариант | Hit@3 | Recall@3 | MRR@3 | Recall@20 |
|---|---|---|---|---|
| Dense | 85.0% | 81.4% | 75.3% | 95.2% |
| BM25 | 78.3% | 76.5% | 70.0% | 94.5% |
| RRF | 86.7% | 82.7% | 74.7% | 95.7% |
| RRF + CE | 86.7% | 84.4% | 79.7% | 95.7% |

## Дополнительность Dense и BM25

| Группа | На глубине 3 | RRF Hit@3 | На глубине 20 | RRF Hit@3 |
|---|---|---|---|---|
| Оба | 44 | 44 | 57 | 52 |
| Только Dense | 7 | 4 | 1 | 0 |
| Только BM25 | 3 | 3 | 1 | 0 |
| Ни один | 6 | 1 | 1 | 0 |

По правилу MRR@3 → Recall@3 → простота выбран RRF + CE. Выбор записан до проверки holdout.

# Ответы и время поиска

| Часть | Вариант | Accuracy | Ссылка | Обоснование | SUPPORT | CONTRADICT | NOINFO |
|---|---|---|---|---|---|---|---|
| dev | Dense | 63.3% | 65.0% | 85.0% | 70.0% | 90.0% | 30.0% |
| dev | RRF | 62.2% | 61.7% | 86.7% | 80.0% | 86.7% | 20.0% |
| dev | RRF + CE | 66.7% | 65.0% | 86.7% | 76.7% | 96.7% | 26.7% |
| holdout | Dense | 53.8% | 55.5% | 89.8% | 72.3% | 73.5% | 24.4% |
| holdout | RRF + CE | 54.8% | 60.9% | 95.3% | 77.7% | 76.5% | 19.5% |

На dev RRF + CE относительно Dense исправил 5 ответов и испортил 2. На holdout выбранный вариант исправил 12 и испортил 10.

## Поиск на holdout, 128 утверждений с обоснованием

| Вариант | Hit@3 | Recall@3 | MRR@3 | Recall@20 |
|---|---|---|---|---|
| Dense | 89.8% | 89.1% | 86.1% | 98.4% |
| RRF + CE | 95.3% | 93.0% | 86.8% | 99.6% |

## Задержка поиска на dev, мс на запрос

| Этап / вариант | Медиана | Минимум | Максимум |
|---|---|---|---|
| Dense | 24.48 | 21.02 | 73.07 |
| BM25 | 7.71 | 0.63 | 14.43 |
| Только объединение | 0.06 | 0.05 | 0.15 |
| Только cross-encoder | 986.44 | 632.25 | 1140.34 |
| RRF | 32.81 | 24.06 | 80.92 |
| RRF + CE | 1021.35 | 664.14 | 1179.67 |

Для RRF и RRF + CE полное время включает оба исходных поиска. Cross-encoder оценивает 1800 пар на dev и 4200 на holdout. Время чтения результатов не учитывалось.

# Четыре трейса

## Находка BM25

ID 1274. The tip of the inner tube of the toxic type VI secretion system (T6SS) antibacterial effector in Escherichia coli (E. coli) carries toxic effector proteins.

Dense: 27731651 (#1), 22632303 (#2), 7145763 (#3), 4406819 (#4), 7481159 (#5)

BM25: 7481159 (#1), 4406819 (#2), 7145763 (#3), 27731651 (#4)

RRF: 27731651 (#1, D=0.0164, B=0.0156), 7481159 (#2, D=0.0154, B=0.0164), 4406819 (#3, D=0.0156, B=0.0161)

RRF + CE: 4406819 (#1), 27731651 (#2), 7481159 (#3)

Обоснование передано: Dense — нет, RRF — да, RRF + CE — да.

Этап: Dense — нет нужного документа в top-3, RRF — обоснование в промпте, RRF + CE — обоснование в промпте.

Dense → { "label": "CONTRADICT", "doc_id": "22632303", "sentences": [ 0 ] }; переданы {'27731651': [0, 1, 2, 3, 4, 5], '22632303': [0, 1, 2, 3, 4, 5, 6, 7, 8], '7145763': [0, 1, 2, 3, 4, 5, 6]}

RRF → { "label": "SUPPORT", "doc_id": "4406819", "sentences": [ 0, 2, 5 ] }; переданы {'27731651': [0, 1, 2, 3, 4, 5], '7481159': [0, 1, 2, 3, 4, 5, 6, 7, 8], '4406819': [0, 1, 2, 3, 4, 5, 6, 7]}

RRF + CE → { "label": "SUPPORT", "doc_id": "4406819", "sentences": [ 0, 1, 2, 5, 7 ] }; переданы {'4406819': [0, 1, 2, 3, 4, 5, 6, 7], '27731651': [0, 1, 2, 3, 4, 5], '7481159': [0, 1, 2, 3, 4, 5, 6, 7, 8]}

## Находка Dense

ID 756. Many proteins in human cells can be post-translationally modified at lysine residues via acetylation.

Dense: 27134527 (#1), 17919731 (#2), 2831620 (#3), 25901598 (#11)

BM25: 17919731 (#1), 27134527 (#2), 3230361 (#3), 25901598 (#9), 2831620 (#10)

RRF: 17919731 (#1, D=0.0161, B=0.0164), 27134527 (#2, D=0.0164, B=0.0161), 8646760 (#3, D=0.0156, B=0.0154), 2831620 (#4, D=0.0159, B=0.0143), 25901598 (#6, D=0.0141, B=0.0145)

RRF + CE: 27134527 (#1), 17919731 (#2), 25901598 (#3), 2831620 (#4)

Обоснование передано: Dense — да, RRF — нет, RRF + CE — нет.

Этап: Dense — обоснование в промпте, RRF — нет нужного документа в top-3, RRF + CE — нет нужного документа в top-3.

Dense → { "label": "SUPPORT", "doc_id": "27134527", "sentences": [ 0, 1, 4 ] }; переданы {'27134527': [0, 1, 2, 3, 4], '17919731': [0, 1, 2, 3], '2831620': [0, 1, 2, 3, 4]}

RRF → { "label": "SUPPORT", "doc_id": "17919731", "sentences": [ 2 ] }; переданы {'17919731': [0, 1, 2, 3], '27134527': [0, 1, 2, 3, 4], '8646760': [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]}

RRF + CE → { "label": "SUPPORT", "doc_id": "27134527", "sentences": [ 0, 1, 4 ] }; переданы {'27134527': [0, 1, 2, 3, 4], '17919731': [0, 1, 2, 3], '25901598': [0, 1, 2, 3, 4, 5]}

# Трейсы и выводы

## RRF изменил первые три результата

ID 845. Neutrophil extracellular traps (NETs) are released by ANCA-stimulated neutrophils.

Dense: 29399239 (#1), 9878167 (#2), 2236768 (#3), 17741440 (#5)

BM25: 17741440 (#1), 9878167 (#2), 29399239 (#3), 2236768 (#5)

RRF: 29399239 (#1, D=0.0164, B=0.0159), 9878167 (#2, D=0.0161, B=0.0161), 17741440 (#3, D=0.0154, B=0.0164), 2236768 (#4, D=0.0159, B=0.0154)

RRF + CE: 17741440 (#1), 9878167 (#2), 2236768 (#3)

Обоснование передано: Dense — нет, RRF — да, RRF + CE — да.

Этап: Dense — нет нужного документа в top-3, RRF — обоснование в промпте, RRF + CE — обоснование в промпте.

Dense → { "label": "CONTRADICT", "doc_id": "9878167", "sentences": [ 6 ] }; переданы {'29399239': [0, 1, 2, 3, 4], '9878167': [0, 1, 2, 3, 4, 5, 6], '2236768': [0, 1, 2, 3, 4, 5, 6, 7, 8]}

RRF → { "label": "SUPPORT", "doc_id": "17741440", "sentences": [ 0 ] }; переданы {'29399239': [0, 1, 2, 3, 4], '9878167': [0, 1, 2, 3, 4, 5, 6], '17741440': [0, 1, 2]}

RRF + CE → { "label": "SUPPORT", "doc_id": "17741440", "sentences": [ 1 ] }; переданы {'17741440': [0, 1, 2], '9878167': [0, 1, 2, 3, 4, 5, 6], '2236768': [0, 1, 2, 3, 4, 5, 6, 7, 8]}

## Переранжирование изменило ответ

ID 314. Deamination of cytidine to uridine on the minus strand of viral DNA results in catastrophic G-to-A mutations in the viral genome.

Dense: 544971 (#1), 2638387 (#2), 34498325 (#3), 22703082 (#9)

BM25: 544971 (#1), 2638387 (#2), 24896957 (#3), 4347374 (#5), 22703082 (#13)

RRF: 544971 (#1, D=0.0164, B=0.0164), 2638387 (#2, D=0.0161, B=0.0161), 25787749 (#3, D=0.0154, B=0.0149), 22703082 (#6, D=0.0145, B=0.0137), 4347374 (#13, D=0.0000, B=0.0154)

RRF + CE: 544971 (#1), 2638387 (#2), 22703082 (#3), 4347374 (#11)

Обоснование передано: Dense — нет, RRF — нет, RRF + CE — нет.

Этап: Dense — нет нужного документа в top-3, RRF — нет нужного документа в top-3, RRF + CE — нет нужного документа в top-3.

Dense → { "label": "SUPPORT", "doc_id": "2638387", "sentences": [ 4, 2 ] }; переданы {'544971': [0, 1, 2, 3], '2638387': [0, 1, 2, 3, 4, 5, 6, 7], '34498325': [0, 1, 2, 3, 4, 5, 6, 7]}

RRF → { "label": "SUPPORT", "doc_id": "2638387", "sentences": [ 4, 6 ] }; переданы {'544971': [0, 1, 2, 3], '2638387': [0, 1, 2, 3, 4, 5, 6, 7], '25787749': [0, 1, 2, 3, 4, 5, 6, 7, 8]}

RRF + CE → { "label": "SUPPORT", "doc_id": "544971", "sentences": [ 1 ] }; переданы {'544971': [0, 1, 2, 3], '2638387': [0, 1, 2, 3, 4, 5, 6, 7], '22703082': [0, 1, 2, 3]}

## Выводы

dev: RRF + CE относительно Dense изменил Accuracy на +3.3 п.п.

holdout: RRF + CE относительно Dense изменил Accuracy на +1.0 п.п.

На holdout выше Accuracy у RRF + CE.

На holdout выигрыш составил 2 ответа из 210. Полнота NOINFO изменилась на -4.9 п.п. Медиана поиска на dev больше в 41.7 раза. При приоритете скорости разумно оставить Dense.

Итоговый выбор оценивается на holdout после фиксации параметров. Метрики поиска и доставки обоснования помогают отделить эффект ранжирования от ошибок модели.

## Файлы для проверки

selection.json хранит правило и выбранный вариант. manifest.json хранит данные и ревизии. Списки dev и holdout, полные ответы и summary.json находятся в results. В traces.md есть переданные предложения и ответы для четырёх случаев.

Код и обработка результатов подготовлены с помощью Codex. Таблицы собраны из сохранённых измерений.